## 第 1 页｜数据如何“可用不可见”?

大家好，我们小组今天汇报的主题是 **“数据如何做到可用不可见”。**

大数据真正产生价值，往往离不开共享、分析和计算。但问题在于，数据一旦开始流动和使用，就可能伴随着隐私泄露。

所以隐私保护并不是简单地“不让别人使用数据”，而是希望在保留数据价值的同时，尽可能降低隐私泄露的风险。

---

## 第 2 页｜六类核心技术总览

围绕这个问题，我们选取了六类比较有代表性的隐私保护技术。

它们分别是：

**数据匿名化、差分隐私、同态加密、安全多方计算、联邦学习和零知识证明。**

它们解决的问题其实并不完全相同，可以简单理解成：

从最开始的**隐藏个人身份**，到隐藏个体对统计结果的影响、隐藏数据本身，再到多方联合计算、数据不出本地，以及最后的“证明一件事情成立，但是不泄露秘密”。

接下来我先介绍其中最直观的一类——**数据匿名化。**

---

# 第一部分：数据匿名化

## 第 3 页｜删除姓名，就真的匿名了吗?

先来看一个很简单的问题：

**如果我们把一份医疗数据中的姓名删除，是不是就代表这份数据已经匿名了?**

答案其实是否定的。

比如这张表中，我们虽然删除了姓名，但还保留了年龄、性别、邮编以及疾病信息。

如果一个人知道某位同学是 21 岁、男性，并且住在某个特定邮编区域，那么他就有可能把这些外部信息和数据库中的记录对应起来。

所以，**删除姓名并不等于真正匿名。**

这也是数据匿名化首先要解决的问题：除了姓名、身份证号这些明显的信息以外，还有一些看起来普通的属性，组合起来之后同样可能暴露个人身份。

---

## 第 4 页｜数据中的三类属性

因此，在匿名化中，我们通常会把数据中的属性分成几类。

第一类是**直接标识符。**

比如姓名、身份证号、手机号，这些信息本身就能够直接确定一个人是谁。

第二类是**准标识符。**

比如年龄、性别和邮编。单独看一个年龄可能没什么问题，但是多个属性组合之后，就有可能把范围缩小到某一个具体的人。

第三类是**敏感属性。**

比如疾病、收入和医疗记录。这些往往就是我们真正希望保护的信息。

所以匿名化不能只删除直接标识符，还要重点考虑这些**准标识符是否会导致个人重新被识别。**

---

# 第 5 页 | k-匿名

针对这个问题，一个非常经典的方法就是 **k-匿名。**

它的基本思想其实非常直观：

**不要让一条记录在准标识符上显得特别独特。**

比如当 k 等于 3 时，我们希望对于年龄、性别、邮编这些准标识符来说，一个人的记录至少能够和另外两个人无法区分。

也就是说，仅仅依靠这些准标识符，攻击者最多只能判断：

> “这个人应该是这三个人中的一个。”

但是不能继续确定到底是哪一个人。

所以我们可以把 k-匿名简单理解成：

**让一个人藏进一个至少包含 k 个人的群体中。**

---

# 第 6 页 | 匿名化之前

那具体应该怎么做呢？

来看这张原始数据表。

比如这里有几条医疗记录，其中包含年龄、性别、邮编和疾病。

现在年龄是精确到具体岁数的，邮编也是完整的。

那么像：

**21 岁、男性、邮编 10001**

这样的组合其实非常具体。

如果外部信息足够多，就有可能把这一条记录和现实中的某个人对应起来。

也就是说，这些准标识符的**粒度太细了。**

---

# 第 7 页 | 匿名化之后

于是我们可以对这些数据进行一定程度的处理。

比如：

原来的 **21 岁**，不再保留具体年龄，而是改成：

**20 到 29 岁。**

原来的邮编 **10001**，也不再保留完整信息，而是改成：

**100****。

经过这样的处理之后，原来可以区分不同个人的精确信息，就被模糊成了多个记录共同拥有的特征。

这样一来，数据依然保留了一定的统计价值，比如我们仍然能够研究不同年龄段的疾病情况，但想通过这些信息直接定位到具体个人，就会变得更加困难。

---

# 第 8 页｜泛化与抑制

刚才实际上用到了匿名化中两种很常见的方法。

第一种叫做**泛化，也就是 Generalization。**

它的意思就是，把一个非常具体的值替换成一个更加宽泛的范围。

比如：

21 岁变成 20 到 29 岁，

具体邮编也可以变成一个更大的邮编区域。

另外一种叫做**抑制，也就是 Suppression。**

对于一些特别容易暴露身份的信息，可以直接隐藏其中的一部分，或者对一些非常特殊的记录进行处理。

所以它们的目的其实是一样的：

**降低准标识符的精确程度，让多个记录变得更加相似。**

---

# 第 9 页｜k-匿名的局限

不过，做到 k-匿名之后，就代表隐私问题完全解决了吗？

其实也不是。

来看一个比较极端的例子。

假设这里有三个人，他们经过匿名化之后，年龄和邮编都完全一样。

从身份上来看，我们确实已经无法判断其中某一条记录具体是谁。

但是如果这三个人的疾病全部都是**糖尿病**，那么即使我们不知道这个人到底对应哪一条记录，我们仍然可以推断：

> 只要他属于这个匿名群体，那么他的疾病很可能就是糖尿病。

所以这里可以看到：

**k-匿名主要解决的是身份重新识别的问题，但它不能保证敏感属性完全无法被推断。**

---

# 第 10 页 | 从 k-匿名到 l-多样性、t-接近性

也正因为存在这个问题，后续又出现了 **l-多样性** 和 **t-接近性** 等方法。

它们可以看作传统匿名化技术进一步演进的结果。原来的整体框架也是按照 **k-匿名 → l-多样性 → t-接近性** 这条路线展开的。

简单来说：

k-匿名主要关注的是：

**一个人的身份能不能从准标识符中被识别出来。**

而 l-多样性进一步关注：

**同一个匿名群体中的敏感信息是不是足够多样。**

t-接近性则进一步考虑：

**一个匿名群体中的敏感属性分布，与整个数据集的总体分布是否足够接近。**

所以从 k-匿名到后面的这些方法，保护的重点实际上是在不断从“隐藏身份”向“降低敏感信息推断风险”扩展。

---

# 第 11 页 | 过渡到差分隐私

但即使经过这些匿名化处理，也仍然存在一个新的问题。

如果我们不直接发布原始数据，而只是允许别人不断对数据库进行**统计查询**，是否就一定安全？

答案仍然是否定的。

攻击者有可能通过多次统计结果之间的差异，进一步推断某一个人的信息。你们整体框架的下一部分也正是从这个问题开始。

因此，接下来就需要另一类方法：

**差分隐私。**

它所关心的问题不再只是：

> “数据表中的身份有没有被隐藏？”

而是：

> **“一个人的数据是否存在，会不会明显影响最终的统计结果？”**

接下来这一部分由下一位同学继续介绍。

---

# 你实际讲的时候建议注意两点

第一，**第 1 ~ 2 页不要拖时间。**正常讲下来最好控制在 **30 ~ 40 秒。**真正值得慢下来的是第 5 ~ 9 页，也就是：

**k-匿名是什么 → 怎么匿名 → 为什么还不够。**

第二，第 6 ~ 7 页不要把表格逐行念一遍。你只需要指着一两项变化说：

> “大家注意年龄从 21 岁变成了 20 ~ 29 岁，邮编从完整的 10001 变成了 100**。”

观众就能理解你做了什么。

这样整段汇报听起来会更像你在**借 PPT 讲一个问题是怎么一步步解决的**，而不是在背定义。